

딥러닝 파이토치 교과서 5장 Part 2 (5.3~)

5장 합성곱 신경망 I

5.3 전이 학습

일반적으로 합성곱 신경망 기반의 딥러닝 모델을 제대로 훈련시키려면 많은 양의 데이터가 필요하다. 그런데 충분히 큰 데이터셋을 얻는 것은 쉽지 않은데, 큰 데이터셋을 확보하려면 많은 돈과 시간이 필요하기 때문이다.

이러한 현실적인 어려움을 해결한 것이 전이 학습(transfer learning)이다.

- 전이 학습이란 이미지넷(ImageNet)처럼 아주 큰 데이터셋을 써서 훈련된 모델의 가중치를 가져와 우리가 해결하려는 과제에 맞게 보정해서 사용하는 것을 의미한다.
- 아주 큰 데이터셋을 사용하여 훈련된 모델을 사전 훈련된 모델(네트워크)이라고 한다.
- 결과적으로 비교적 적은 수의 데이터를 가지고도 우리가 원하는 과제를 해결할 수 있다.

전이 학습을 위한 방법으로는 특성 추출과 미세 조정 기법이 있다.

5.3.1 특성 추출 기법

특성 추출(feature extractor)은 ImageNet 데이터셋으로 사전 훈련된 모델을 가져온 후 마지막에 완전연결층 부분만 새로 만드는 것이다. 즉, 학습할 때는 마지막 완전연결층(이미지의 카테고리를 결정하는 부분)만 학습하고 나머지 계층들은 학습되지 않도록 한다.

특성 추출은 이미지 분류를 위해 두 부분으로 구성된다.

1. 합성곱층: 합성곱층과 풀링층으로 구성
2. 데이터 분류기(완전연결층): 추출된 특성을 입력받아 최종적으로 이미지에 대한 클래스를 분류하는 부분

사전 훈련된 네트워크의 합성곱층(가중치 고정)에 새로운 데이터를 통과시키고, 그 출력을 데이터 분류기에서 훈련시킨다.

여기에서 사용 가능한 이미지 분류 모델은 다음과 같다.

- Xception
- Inception V3
- ResNet50
- VGG16
- VGG19
- MobileNet

특성 추출 예제에서 다룬 개념은 다음과 같다.

1. torchvision.transforms
 - 이미지 데이터를 변환하여 모델(네트워크)의 입력으로 사용할 수 있게 변환해 준다.
 - Resize: 이미지의 크기를 조정한다.

- RandomResizedCrop: 이미지를 랜덤한 크기 및 비율로 자른다. Resize가 합성곱층을 통과하기 위해 이미지 크기를 조정하는 전처리 과정이라면, RandomResizedCrop은 데이터 확장 용도로 사용된다. 이미지를 랜덤한 비율로 자른 후 데이터 크기를 조정한다.
- RandomHorizontalFlip: 이미지를 랜덤하게 수평으로 뒤집는다.
- ToTensor: 이미지 데이터를 텐서로 변환한다.

2. datasets.ImageFolder

- 데이터로더가 데이터를 불러올 대상(혹은 경로)과 방법(전처리)을 정의한다.

3. DataLoader

- 앞에서 정의한 데이터셋을 데이터로더에 할당하는데, 이때 한 번에 불러올 데이터양을 결정하는 batch_size를 지정한다.
- num_workers: 데이터를 불러올 때 하위 프로세스를 몇 개 사용할지 설정하는데, 이때 너무 많은 하위 프로세스를 설정하게 되면 오류가 발생하거나 메모리 부족 현상이 발생할 수 있다.
- shuffle: 데이터를 무작위로 섞을지를 지정한다.

4. 사전 훈련된 모델 내려받기

- pretrained=True로 설정하면 사전 학습된 가중치를 사용하겠다는 의미다.
- ResNet18은 50개의 계층으로 구성된 합성곱 신경망이다. ImageNet 데이터베이스의 100만 개가 넘는 영상을 이용하여 훈련된 신경망으로 전이 학습에 사용되도록 사전 훈련된 모델을 제공하고 있다. 하지만 ResNet18은 입력 제약이 매우 크고, 충분한 메모리(RAM)가 없으면 학습 속도가 느릴 수 있는 단점이 있다.

5. 사전 훈련된 모델의 파라미터 학습 유무 지정

- requires_grad = False로 설정하면 역전파 중 파라미터들에 대한 변화를 계산할 필요가 없음을 나타낸다.
- 즉, 모델의 일부를 고정하고 나머지를 학습하고자 할 때 requires_grad = False로 설정한다. 이때 모델의 일부는 합성곱층(convolutional layer)과 풀링(pooling)층을 의미한다.

6. 완전연결층 추가

- 내려받은 사전 훈련된 모델의 마지막 부분에 완전연결층을 추가한다. 추가된 완전연결층은 우리가 분류하려는 클래스를 분류하는 용도로 사용된다.

7. 모델 학습을 위한 함수 생성

- 순전파 학습(model(inputs))으로 출력을 계산하고, 손실 함수로 오차를 계산한다.
- 역전파 학습(loss.backward())으로 기울기를 계산하고, optimizer.step()으로 기울기를 업데이트한다.
- 출력 결과와 레이블의 오차를 계산한 결과를 누적하여 저장하고, 출력 결과와 레이블이 동일한지 확인한 결과(정확도)도 누적하여 저장한다.

8. 파라미터 학습 결과를 옵티마이저에 전달

- requires_grad가 True로 설정된, 즉 학습하도록 설정된 파라미터들만 옵티마이저에 전달한다.

9. 모델 평가 함수

- with torch.no_grad()는 autograd를 사용하지 않겠다는 의미다. 즉, 역전파를 위한 기울기 계산이 필요하지 않은 평가 단계에서 사용한다.

- `torch.max`는 주어진 텐서 배열의 최댓값이 들어 있는 `index`를 반환하는 함수다.
- `preds.eq(labels)`는 `preds` 배열과 `labels`가 일치하는지 검사하는 용도로 사용한다. 뒤에 사용된 `.sum()`은 모델의 예측 결과와 정답(레이블)이 일치하는 것들의 개수 합을 숫자로 출력한다.

전이 학습을 통해 사전 훈련된 모델을 사용하면, 모델의 네트워크를 개발자가 직접 구현하고 최적의 파라미터 값을 찾는 것보다 손쉽게 모델을 학습시킬 수 있기 때문에 실무에서도 많이 사용된다.

5.3.2 미세 조정 기법

미세 조정(fine-tuning) 기법은 특성 추출 기법에서 더 나아가 사전 훈련된 모델과 합성곱층, 데이터 분류기의 가중치를 업데이트하여 훈련시키는 방식이다.

- 특성 추출은 목표 특성을 잘 추출했다는 전제하에 좋은 성능을 낼 수 있다.
- 특성이 잘못 추출되었다면(예를 들어 ImageNet 데이터셋의 이미지 특징과 전자상거래 물품의 이미지 특징이 다르다면) 미세 조정 기법으로 새로운(전자상거래) 이미지 데이터를 사용하여 네트워크의 가중치를 업데이트 해서 특성을 다시 추출할 수 있다.
- 즉, 사전 학습된 모델을 목적에 맞게 재학습시키거나 학습된 가중치의 일부를 재학습시키는 것이다.

미세 조정 기법은 사전 훈련된 네트워크를 미세 조정하여 분석하려는 데이터셋에 잘 맞도록 모델의 파라미터를 조정하는 기법이다. 미세 조정 과정에서 많은 연산량이 필요하기 때문에 CPU보다는 GPU를 사용하길 권장한다.

미세 조정 기법은 훈련시키려는 데이터셋의 크기와 사전 훈련된 모델에 따라 다음 전략을 세울 수 있다.

1. 데이터셋이 크고 사전 훈련된 모델과 유사성이 작을 경우: 모델 전체를 재학습시킨다. 데이터셋 크기가 크기 때문에 재학습시키는 것이 좋은 전략이다.
2. 데이터셋이 크고 사전 훈련된 모델과 유사성이 클 경우: 합성곱층의 뒷부분(완전연결층과 가까운 부분)과 데이터 분류기를 학습시킨다. 데이터셋이 유사하기 때문에 전체를 학습시키는 것보다는 강한 특징이 나타나는 합성곱층의 뒷부분과 데이터 분류기만 새로 학습하더라도 최적의 성능을 낼 수 있다.
3. 데이터셋이 작고 사전 훈련된 모델과 유사성이 작을 경우: 합성곱층의 일부분과 데이터 분류기를 학습시킨다. 데이터가 적기 때문에 일부 계층에 미세 조정 기법을 적용한다고 해도 효과가 없을 수 있다. 따라서 합성곱층 중 어디까지 새로 학습시켜야 할지 적당히 설정해 주어야 한다.
4. 데이터셋이 작고 사전 훈련된 모델과 유사성이 클 경우: 데이터 분류기만 학습시킨다. 데이터가 적기 때문에 많은 계층에 미세 조정 기법을 적용하면 과적합이 발생할 수 있다. 따라서 최종 데이터 분류기인 완전연결층에 대해서만 미세 조정 기법을 적용한다.

미세 조정은 파라미터 업데이트 과정에서 파라미터에 큰 변화를 주게 되면 과적합 문제가 발생할 수 있기 때문에 정교하고 미세한 파라미터 업데이트가 필요하다.

5.4 설명 가능한 CNN

설명 가능한 CNN(explainable CNN)은 딥러닝 처리 결과를 사람이 이해할 수 있는 방식으로 제시하는 기술이다.

- CNN은 블랙박스과 같아 내부에서 어떻게 동작하는지 설명하기 어렵다.
- 따라서 CNN으로 얻은 결과는 신뢰하기 어려운데, 이를 해결하려면 CNN 처리 과정을 시각화해야 할 필요성이 있다.

- CNN을 구성하는 각 중간 계층부터 최종 분류까지 입력된 이미지에서 특성이 어떻게 추출되고 학습하는지를 시각적으로 설명할 수 있어야 결과에 대한 신뢰성을 얻을 수 있다.
- CNN의 시각화 방법에는 필터에 대한 시각화와 특성 맵에 대한 시각화가 있다.

5.4.1 특성 맵 시각화

특성 맵(feature map)(혹은 활성화 맵)은 입력 이미지 또는 다른 특성 맵처럼 필터를 입력에 적용한 결과다. 따라서 특정 입력 이미지에 대한 특성 맵을 시각화한다는 의미는 특성 맵에서 입력 특성을 감지하는 방법을 이해할 수 있도록 돕는 것이다.

특성 맵 시각화 예제에서 다룬 개념은 다음과 같다.

1. hook 기능

- 파이토치는 매 계층마다 print 문을 사용하지 않더라도 hook 기능을 사용하여 각 계층의 활성화 함수 및 기울기 값을 확인할 수 있다.
- register_forward_hook의 목적은 순전파 중에 각 네트워크 모듈의 입력 및 출력을 가져오는 것이다.
- o와 z처럼 특정한 값으로 정의되지 않은 중간 변수(계산 결과에 따라 값이 달라질 수 있는 변수)에 대해서는 파이토치가 기울기 값을 저장하지 않는데, register_hook(hook_fn)을 사용하면 중간 변수의 기울기 값도 확인할 수 있다.

2. 로그 소프트맥스(log_softmax())

- 신경망 말단의 결과값들을 확률 개념으로 해석하기 위해 소프트맥스(softmax) 함수의 결과에 log 값을 취한 연산이다.
- 소프트맥스를 사용하지 않고 로그 소프트맥스를 사용하는 이유는 소프트맥스는 기울기 소멸 문제(vanishing gradient problem)에 취약하기 때문이다.

3. cv2.resize

- 이미지 크기를 변경할 때 사용한다.
- 이미지 크기를 변경할 경우 변형된 이미지의 픽셀을 추정해서 값을 할당해야 하는데, 이러한 상황을 피하고자 이미지상에 존재하는 픽셀 데이터들에 대해 근사 함수를 적용해서 새로운 픽셀 값을 구하는 것이 보간법이다. 즉, 추정해야 하는 픽셀을 보간법을 이용하여 값을 할당한다.

4. unsqueeze()

- 1차원 데이터를 생성하는 함수다. 즉, 이미지 데이터를 텐서로 변환하고, 그 변환된 데이터를 1차원으로 변경하겠다는 의미다.

특성 맵을 계층별로 확인해 보면 다음과 같은 경향이 있다.

- 입력층과 가까운 계층일수록 입력 이미지의 형태가 많이 유지된다.
- 학습이 진행되어 출력층에 가까운 계층으로 갈수록 원래 입력 이미지의 형태는 찾아볼 수 없게 되고, 이미지 특징들만 전달되는 것을 확인할 수 있다.

최근 딥러닝 결과에 대한 신뢰성이 문제가 되면서 설명 가능한 인공지능이 이슈가 되고 있는데, CNN은 필터와 특성 맵을 시각화해서 CNN 결과의 신뢰성을 확보할 수 있다.

5.5 그래프 합성곱 네트워크

그래프 합성곱 네트워크(graph convolutional network)는 그래프 데이터를 위한 신경망이다.

5.5.1 그래프란

그래프는 방향성이 있거나(directed) 없는(undirected) 에지로 연결된 노드(nodes=vertices)의 집합이다. 여기에서 노드와 에지는 일반적으로 풀고자 하는 문제에 대한 전문가 지식이나 직관 등으로 구성된다.

그래프의 구성 요소는 다음과 같다.

1. 노드(node, vertex): 그래프를 구성하는 원소를 의미한다.
2. 에지(edge): 두 노드를 연결한 선을 의미한다.

즉, 노드는 원소들을 의미하고, 에지는 결합 방법(single, double, triple, aromatic 등)을 의미한다.

5.5.2 그래프 신경망

그래프 신경망(Graph Neural Network, GNN)은 그래프 구조에서 사용하는 신경망을 의미한다. 그래프 데이터에 대한 표현은 다음과 같이 두 단계로 이루어진다.

1. 인접 행렬(adjacency matrix)
 - 노드 n 개를 $n \times n$ 행렬(matrix)로 표현한다.
 - 이렇게 생성된 인접 행렬 내의 값은 ' A_{ij} 는 i 와 j 의 관련성 여부'를 만족하는 값으로 채워 준다.
 - 즉, 인접 행렬 과정은 컴퓨터가 이해하기 쉽게 그래프로 표현하는 과정이라고 할 수 있다.
2. 특성 행렬(feature matrix)
 - 인접 행렬만으로는 특성을 파악하기 어렵기 때문에 단위 행렬을 적용한다.
 - 각 입력 데이터에서 이용할 특성을 선택한다.
 - 특성 행렬에서 각 행은 선택된 특성에 대해 각 노드가 갖는 값을 의미한다(예: 첫 번째 행은 첫 번째 노드의 특성 값).
 - 즉, 특성 행렬 과정을 거쳐 그래프 특성(graph feature)이 추출된다.

5.5.3 그래프 합성곱 네트워크

그래프 합성곱 네트워크(Graph Convolutional Network, GCN)는 이미지에 대한 합성곱을 그래프 데이터로 확장한 알고리즘이다.

그래프 합성곱 네트워크 구조는 다음과 같이 이루어진다.

1. 그래프 데이터를 입력받는 그래프 합성곱층
2. 특성 행렬을 하나의 벡터로 변환하는 리드아웃(readout)
3. 그래프 특성과 결합되는 완전연결층 (회귀 혹은 분류를 수행)

여기에서 리드아웃(readout)은 특성 행렬을 하나의 벡터로 변환하는 함수다. 즉, 전체 노드의 특성 벡터에 대해 평균을 구하고 그래프 전체를 표현하는 하나의 벡터를 생성한다.

GCN에서 가장 중요한 부분은 그래프 합성곱층(graph convolutional layer)이다. 그래프 합성곱층을 이용한 그래프 형태의 데이터는 행렬 형태의 데이터로 변환되어 딥러닝 알고리즘을 적용할 수 있기 때문이다(기존 그래프 형태의 데이터로는 딥러닝 알고리즘을 적용할 수 없다).

또한, GCN은 다음과 같은 곳에서 활용된다.

1. SNS에서 관계 네트워크
2. 학술 연구에서 인용 네트워크
3. 3D Mesh