


2주차 : 딥러닝 파이토치 교과서 4장

4장. 딥러닝 시작


4.1 : 인공 신경망의 한계와 딥러닝 출현

- 퍼셉트론 : 다수의 신호를 입력으로 받아 하나의 신호를 출력




- 논리 게이트
 - AND게이트 : 모든 입력이 1일때 작동

▼ 그림 4-2 AND 게이트




- OR게이트 : 둘 중 하나만 1이거나 둘다 1일때 작동

▼ 그림 4-3 OR 게이트



- XOR게이트(배타적 논리합) : 두개 중 한개만 1일때 작동
→ 데이터가 비선형적으로 분리, 제대로 된 분류가 어려움


▼ 그림 4-3 OR 게이트



- ⇒ 해결책 : 다중 퍼셉트론 (입력층과 출력층 사이에 하나 이상의 중간층을 둔다)
→ 은닉층이 여러개 있는 심층 신경망(DNN) = 딥러닝


4.2 : 딥러닝 구조

▼ 그림 4-5 딥러닝 구조



- 층
 - 입력층 : 데이터를 받아들이는 층
 - 은닉층 : 모든 입력 노드부터 입력 값을 받아 가중합을 계산하고, 이 값을 활성화 함수에 적용하여 출력층에 전달하는 층
 - 출력층 : 신경망의 최종 결과값이 포함된 층
- 가중치 : 노드와 노드 간 연결 강도 → 입력 값의 연산 결과를 조정하는 역할을 함
- 바이어스 : 가중합에 더해 주는 상수
 - 하나의 뉴런에서 활성화 함수를 거쳐 최종적으로 출력되는 값을 조절하는 역할을 함
- 가중합(=전달 함수) : 가중치와 신호의 곱을 합한 것 → 이 가중합을 활성화 함수로 보냄

▼ 그림 4-7 전달 함수



가중합을 구하는 공식은 다음과 같습니다.

$$\sum_i w_i x_i + b$$

(w : 가중치, b : 바이어스)

• 함수

- 활성화 함수 : 신호를 입력받아 이를 적절히 처리하여 출력해 주는 함수 (비선형 함수)

Ex) 시그모이드, 하이퍼볼릭 탄젠트, ReLU 등

- 시그모이드 함수 : 선형 함수의 결과를 0~1 사이의 비선형 형태로 변형함
 - a. 기울기 소멸 문제 존재
 - b. 결과값의 평균이 0이 아닌 양수로 편향되는 문제 존재
- 하이퍼볼릭 탄젠트 함수 : 선형 함수의 결과를 -1~1 사이의 비선형 형태로 변형함
 - a. 기울기 소멸 문제 존재
 - b. 시그모이드의 문제 b 해결 가능
- ReLU 함수 : 입력(x)이 음수이면 0을 출력, 양수이면 x 를 출력 - 일반적으로 은닉층에서 사용
 - a. 경사하강법에 영향을 주지 않음 → 학습 속도가 빠름

- b. 기울기 소멸 문제 발생하지 않음
 - c. 음수 값을 입력받으면 항상 0을 출력 → 학습 능력 감소
- Leaky ReLU 함수 : 입력(x)이 음수이면 0이 아닌 매우 작은 수를 반환
 - a. ReLU 함수의 문제 c 해결 가능
- 소프트맥스 함수 : 입력 값을 0~1사이에 출력되도록 정규화
 - 출력 값의 총합들이 항상 1 - 일반적으로 출력층에서 사용
- 손실 함수 : 가중치 학습을 위해 출력 함수의 결과와 실제 값 간의 오차를 측정하는 함수
- Ex) MSE, Cross Entropy Error
- 평균 제곱 오차 (MSE)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\left(\begin{array}{l} \hat{y}_i: \text{신경망의 출력(신경망이 추정한 값)} \\ y_i: \text{정답 레이블} \\ i: \text{데이터의 차원 개수} \end{array} \right)$$


- Cross Entropy Error

$$CrossEntropy = - \sum_{i=1}^n y_i \log \hat{y}_i$$

$$\left(\begin{array}{l} \hat{y}_i: \text{신경망의 출력(신경망이 추정한 값)} \\ y_i: \text{정답 레이블} \\ i: \text{데이터의 차원 개수} \end{array} \right)$$

- 딥러닝 학습

♥ 그림 4-12 순전파와 역전파




1. 순전파 : 모든 뉴런이 이전 층의 뉴런에서 수신한 정보에 변환(가중합 및 활성화 함수)를 적용하여 다음 층의 뉴런으로 전송
→ 데이터가 모든 층을 통과하고 모든 뉴런이 계산을 완료하면 그 예측 값은 출력층에 도달하게 됨
2. 역전파 : 손실함수로 오차 측정 → 손실 함수의 비용이 0에 가까워지도록 훈련을 반복하며 가중치 조정

• 딥러닝의 문제점과 해결 방안


- 과적합 문제 : 훈련 데이터를 과하게 학습해서 발생 → 검증 데이터에 대해 오차 증가할 수 있음
 - 해결책 : 드롭아웃 - 학습 과정 중 임의로 일부 노드들을 학습에서 제외
- 기울기 소멸 문제 : 기울기 소멸 → 학습되지 못하고(오차를 줄이지 못하고) 그 상태로 수렴
 - 해결책 : 시그모이드, 하이퍼볼릭 탄젠트 대신 ReLU 활성화 함수 사용
- 경사하강법 시행 중 성능이 나빠지는 문제

- 배치 경사 하강법 : 전체 데이터셋에 대한 오류를 구한 후 기울기를 한번만 계산하여 모델의 파라미터 업데이트 → 학습이 오래 걸림
- 확률적 경사 하강법 (SGD) : 임의로 선택한 데이터에 대해 기울기 계산 → 속도가 빠름
- 미니 배치 경사 하강법 : 전체 데이터셋을 미니 배치 여러개로 나눈 후 각 배치의 기울기를 구해 평균 기울기를 이용하여 모델의 파라미터 업데이트
→ 배치 경사 하강법보다 속도가 빠르고, SGD보다 안정적
→ 파라미터 변경 폭의 경우에도 SGD보다 빠르고 안정적
- 옵티마이저 : 학습 속도와 운동량 조정

▼ 그림 4-18 경사 하강법의 유형



♥ 그림 4-22 옵티마이저 유형




- 딥러닝을 사용할 때 이점
 - 특성 추출 (feature extraction) : 데이터별로 어떤 특징을 가지고 있는지 찾아내고, 그것을 토대로 데이터를 벡터로 변환하는 작업
 - 딥러닝의 경우 특성 추출 과정을 알고리즘에 통합
 - cf. 딥러닝 학습을 이용한 특성 추출은 데이터 사례가 많을수록 성능이 향상됨

4.3 : 딥러닝 알고리즘


- 심층 신경망 (DNN) : 입력층과 출력층 사이에 다수의 은닉층을 포함하는 인공 신경망
 - 다수의 은닉층 → 다양한 비선형적 관계 학습 가능
 - 학습을 위한 연산량이 많음, 기울기 소멸 문제 등 발생 가능
 - 드롭아웃, ReLU함수, 배치 정규화 등의 적용 필요
- 합성곱 신경망 (Convolutional Neural Network, CNN) : 영상 및 사진이 포함된 이미지 데이터에서 객체를 탐색하거나 객체 위치를 찾아내는 데 유용한 신경망

▼ 그림 4-25 합성곱 신경망



- 각 층의 입출력 형상 유지
- 이미지의 공간 정보를 유지하면서 인접 이미지와 차이가 있는 특징을 효과적으로 인식
- 복수 필터로 이미지의 특징을 추출하고 학습함
- 추출한 이미지의 특징을 모으고 강화하는 풀링층 존재
- 필터를 공유 파라미터로 사용 → 일반 nn과 비교하여 학습 파라미터가 매우 적음
- 순환 신경망 (Recurrent Neural Network, RNN) : 시계열 데이터같은 시간 흐름에 따라 변화하는 데이터를 학습하기 위한 인공 신경망 → 자연어 처리 분야에서 자주 쓰임


▼ 그림 4-26 순환 신경망



- 순환 : 자기 자신을 참조한다 → 현재 결과가 이전 결과와 연관이 있다.
- 시간성을 가진 데이터가 많음 → 시간성 정보를 이용하여 데이터의 특징을 잘 다룸


- 시간에 따라 내용이 변함 → 데이터는 동적이고, 길이가 가변적임
- 기울기 소멸 문제 존재 → LSTM(Long-Short Term Memory) 활용 : 메모리 개념 도입
- 제한된 볼츠만 머신 : 가시층과 은닉층으로 구성, 각 가시층, 은닉층 간에 연결은 없음

♥ 그림 4-27 제한된 볼츠만 머신



- 차원 감소, 분류, 선형 회귀 분석, 협업 필터링, 특성 값 학습, 주제 모델링에 활용
- 기울기 소멸 문제를 해결하기 위한 사전 학습 용도로 활용 가능
- 심층 신뢰 신경망 (DBN)의 요소로 활용
- 심층 신뢰 신경망 (Deep Belief Network, DBN) : 제한된 볼츠만 머신을 여러 층으로 쌓은 형태
 - 레이블이 없는 데이터에 대한 비지도 학습 가능, 일반화와 추상화 과정을 구현할때 유용
- 심층 신뢰 신경망의 학습 절차
 - a. 가시층과 은닉층 1에 제한된 볼츠만 머신을 사전 훈련한다.
 - b. 첫번째 층 입력 데이터와 파라미터 고정 → 두번째 층 제한된 볼츠만 머신을 사전 훈련
 - c. 원하는 층 개수만큼 제한된 볼츠만 머신을 쌓아 올려 전체 DBN 완성

♥ 그림 4-28 심층 신뢰 신경망



- 순차적으로 DBN 학습 → 계층적 구조 생성
- 비지도 학습으로 학습
- 위로 올라갈수록 추상적 특성 학습
- 학습된 가중치 → 다중 퍼셉트론의 가중치 초깃값으로 사용