


4장 딥러닝 시작

4장 딥러닝 시작

4.1 인공 신경망의 한계와 딥러닝 출현

퍼셉트론

- 프랭크 로젠블라트가 1957년에 고안한 선형 분류기
- 오늘날 인공 신경망과 딥러닝의 기원이 되는 알고리즘
- 다수의 입력 신호를 받아 하나의 신호를 출력하는 구조



- 출력값 1 과 0
 - 1: 신호의 전달
 - 0: 신호의 미전달

논리 게이트

AND 게이트

- 모든 입력값이 1 일 때만 1 출력
- 선형 분리가 가능한 구조

x1	x2	y
0	0	0
1	0	0
0	1	0
1	1	1

OR 게이트

- 입력값 중 하나 이상이 1이면 1 출력
- 선형 분리가 가능한 구조

x1	x2	y
0	0	0
1	0	1
0	1	1
1	1	1

XOR 게이트

- 두 입력값 중 하나만 1일 때 1 출력
- 배타적 논리합 구조
- 비선형적으로 분리되는 데이터
- 단층 퍼셉트론을 이용한 학습 불가능

x1	x2	y
0	0	0
1	0	1
0	1	1
1	1	0

다층 퍼셉트론의 등장

- XOR 문제 해결을 위한 구조
- 입력층과 출력층 사이에 하나 이상의 은닉층 배치
- 비선형적으로 분리되는 데이터의 학습 가능

심층 신경망 (Deep Neural Network, DNN)

- 입력층과 출력층 사이에 다수의 은닉층을 포함한 신경망
- 심층 신경망을 이용한 학습: 딥러닝

4.2 딥러닝 구조

- 여러 층으로 구성된 인공 신경망을 사용한 학습
- 입력층, 은닉층, 출력층으로 구성된 구조
- 가중치, 바이어스, 활성화 함수, 손실 함수 등의 사용

4.2.1 딥러닝 용어

신경망의 층

- **입력층(input layer)**
 - 데이터의 입력을 담당하는 층
- **은닉층(hidden layer)**
 - 입력값을 받아 가중합 계산
 - 가중합에 활성화 함수 적용
 - 계산 결과를 다음 층으로 전달
- **출력층(output layer)**
 - 신경망의 최종 결과값을 포함하는 층

가중치


- 입력값이 연산 결과에 미치는 영향력의 조절 요소
- 노드와 노드 사이의 연결 강도
 - 큰 가중치: 해당 입력의 영향력 증가
 - 작은 가중치: 해당 입력의 영향력 감소

바이어스

- 가중합에 더하는 상수
- 활성화 함수를 거친 최종 출력값의 조절
- 활성화 여부를 결정하는 기준값의 이동

가중합 또는 전달 함수

- 입력 신호와 가중치의 곱을 모두 더한 값
- 활성화 함수로 전달되는 값
- 전달 함수(transfer function)라는 명칭 사용



- 가중합을 구하는 공식

$$\sum_i w_i x_i + b$$


(w : 가중치, b : 바이어스)

활성화 함수

- 전달 함수에서 받은 값의 변환
- 일정한 기준에 따른 출력값 결정
- 비선형 관계 표현을 위한 함수


1. 시그모이드 함수

$$f(x) = \frac{1}{1 + e^{-x}}$$




- 선형 함수의 결과를 0~1 사이로 변환
- 분류 문제의 확률 표현에 사용
- 로지스틱 회귀 등에 활용
- 깊은 신경망에서 '기울기 소멸 문제' 발생 가능

2. 하이퍼볼릭 탄젠트 함수




- 선형 함수의 결과를 -1~1 사이로 변환
- 시그모이드 함수의 양수 편향 문제 보완
- 기울기 소멸 문제의 잔존

3. 렐루 함수



- 입력값이 음수인 경우 0 출력, 입력값이 양수인 경우 입력값 그대로 출력
- 빠른 학습 속도
- 기울기 소멸 문제의 완화
- 일반적으로 은닉층에서 사용

4. 리키 렐루 함수



- 렐루 함수의 문제점 보완
- 음수 입력에 대해 작은 값 출력

5. 소프트맥스 함수

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$$

- 입력값을 0~1 사이의 값으로 정규화하여, 출력 값들의 총합이 항상 1 이 되도록 함
- 다중 분류 문제에서 사용
- 일반적으로 출력층의 활성화 함수로 사용

손실 함수

- 모델의 예측값과 실제값 사이의 오차 측정
- 가중치 학습을 위한 평가 지표
 - 큰 손실값: 예측값과 실제값의 큰 차이
 - 작은 손실값: 예측값과 실제값의 작은 차이
- 경사 하강법을 통한 손실값 최소화

1. 평균 제곱 오차

- Mean Squared Error (MSE), 예측값과 실제값 차이의 제곱에 대한 평균
- 주로 회귀 문제에서 사용
- 평균 제곱 오차를 구하는 수식

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\left(\begin{array}{l} \hat{y}_i: \text{신경망의 출력(신경망이 추정한 값)} \\ y_i: \text{정답 레이블} \\ i: \text{데이터의 차원 개수} \end{array} \right)$$

2. 크로스 엔트로피 오차

- 분류 문제에서 사용
- 원-핫 인코딩된 실제값과 예측 확률의 비교
 - 정답 클래스의 예측 확률이 높을수록 작은 손실
 - 정답 클래스의 예측 확률이 낮을수록 큰 손실
- 크로스 엔트로피를 구하는 수식

$$CrossEntropy = - \sum_{i=1}^n y_i \log \hat{y}_i$$

$$\left(\begin{array}{l} \hat{y}_i: \text{신경망의 출력(신경망이 추정한 값)} \\ y_i: \text{정답 레이블} \\ i: \text{데이터의 차원 개수} \end{array} \right)$$

4.2.2 딥러닝 학습

전체 학습 과정

- 딥러닝 학습은 크게 순전파와 역전파라는 두 단계로 진행됨
- 예측값과 실제값의 오차 감소
- 손실 함수가 θ 에 가까워지도록(=손실값 감소 방향으로) 가중치 조정

순전파(forward propagation)

- 훈련 데이터가 입력층에서 출력층 방향으로 신경망 전체를 통과하는 과정
 - 입력값 수신 → 가중합 계산 → 활성화 함수 적용 → 다음 층으로 전달
 - 최종 출력층에서 예측값 생성

역전파(backpropagation)

- 예측값과 실제값의 오차를 출력층에서 입력층 방향으로 전달하는 과정
 - 손실 함수를 이용한 오차 계산
 - 각 가중치가 오차에 미친 영향 계산
 - 손실값이 감소하는 방향으로 가중치 수정

4.2.3 딥러닝의 문제점과 해결 방안

과적합

- **과적합(overfitting)**: 훈련 데이터를 지나치게 학습하여 새로운 데이터에서 성능이 떨어지는 현상
 - 훈련 데이터에서의 높은 성능
 - 검증 데이터에서의 오차 증가
- **드롭아웃(dropout)**: 학습 과정에서 일부 노드를 임의로 제외하는 과적합 방지 방법
 - 특정 노드에 대한 과도한 의존 방지
 - 다양한 형태의 신경망을 학습하는 효과

```
torch.nn.Dropout(0.5)
```

⇒ 전체 노드 중 50%를 무작위로 선택하여 학습에서 제외

기울기 소멸

- **기울기 소멸(vanishing gradient)**: 역전파 과정에서 출력층의 오차가 앞쪽 은닉층으로 전달되면서 지나치게 작아지는 현상
 - 학습량이 0에 가까워지는 문제
 - 학습 속도 저하 및 오차 감소 중단
- **해결 방안**: 시그모이드나 하이퍼볼릭 탄젠트 대신 렐루 활성화 함수 사용

경사 하강법

- **경사 하강법**: 손실 함수의 값이 최소가 되는 지점을 찾기 위해 기울기가 낮은 방향으로 파라미터를 반복적으로 이동시키는 방법

종류	학습 방법	특징
배치 경사 하강법	전체 훈련 데이터로 기울기 계산	안정적이지만 긴 학습 시간

종류	학습 방법	특징
확률적 경사 하강법	임의로 선택한 하나의 데이터로 기울기 계산	빠르지만 불안정한 파라미터 변경
미니 배치 경사 하강법	데이터를 여러 미니 배치로 나누어 평균 기울기 계산	빠른 속도와 안정성, 실제 학습에서 가장 많이 사용

옵티마이저

경사 하강법의 학습 속도와 운동량을 조절하여 가중치를 효과적으로 갱신하는 방법

• 학습 속도 조정

- **Adagrad**: 많이 변화한 파라미터에는 작은 학습률, 적게 변화한 파라미터에는 큰 학습률 적용. 기울기 누적에 따른 학습률 감소 문제
- **Adadelat**: Adagrad에서 학습률이 지나치게 작아지는 문제 보완
- **RMSProp**: 과거 기울기의 영향을 일정 비율로 조절하여 기울기 누적 문제 방지

• 운동량 조정

- **Momentum**: 현재 기울기와 이전 이동 방향을 함께 반영. 지그재그 이동 감소 및 빠른 학습
- **NAG**: 모멘텀이 적용될 예상 위치에서 기울기를 계산. 최소 지점을 지나치는 문제 보완

• 속도와 운동량의 결합

- **Adam**: Momentum과 RMSProp의 장점을 결합한 방법. 기울기의 평균과 기울기 제곱의 평균을 이용한 가중치 갱신

4.2.4 딥러닝을 사용할 때 이점

특성 추출(feature extraction)

- 데이터의 특징을 찾고 컴퓨터가 처리할 수 있는 벡터로 변환하는 작업
 - 기존 머신 러닝: 사람이 직접 특성 정의, 도메인 전문 지식 필요
 - 딥러닝: 다수의 은닉층을 통해 특성 추출 과정을 알고리즘에 통합

빅데이터의 효율적 활용

- 데이터가 많을수록 특성 추출과 모델 성능 향상
 - 충분한 데이터가 있는 경우 딥러닝의 높은 성능 기대
 - 데이터가 적은 경우 머신 러닝 사용 고려

4.3 딥러닝 알고리즘

4.3.1 심층 신경망(DNN)

입력층과 출력층 사이에 다수의 은닉층을 포함하는 인공 신경망

- 복잡하고 다양한 비선형 관계의 학습 가능
- 많은 연산량과 기울기 소멸 문제 발생 가능
- 드롭아웃, 렐루 함수, 배치 정규화 등을 통한 문제 완화

4.3.2 합성곱 신경망(CNN)

합성곱층과 풀링층을 포함하는 이미지 처리용 신경망

- 이미지에서 객체, 얼굴, 장면의 패턴과 위치 탐색
- 이미지의 공간 정보 유지
- 여러 필터를 이용한 특징 추출
- 풀링층을 통한 특징 수집 및 강화
- 필터 공유에 따른 학습 파라미터 감소
- 대표 모델: LeNet-5, AlexNet, VGG, GoogLeNet, ResNet

4.3.3 순환 신경망(RNN)

음악, 영상, 문장처럼 시간 흐름에 따라 변하는 데이터를 학습하기 위한 신경망

- 현재 결과와 이전 결과의 연관성 활용
- 동적이고 가변적인 길이의 데이터 처리
- 긴 데이터 처리 시 기울기 소멸 문제 발생 가능
- 메모리 개념을 적용한 LSTM을 통한 문제 완화
- 활용 분야: 언어 모델링, 텍스트 생성, 자동 번역, 음성 인식, 이미지 캡션 생성

4.3.4 제한된 볼츠만 머신(RBM)

가시층과 은닉층으로 구성된 모델

- 가시층과 은닉층 사이만 연결되고 같은 층의 노드끼리는 연결되지 않는 구조
- 차원 감소, 분류, 선형 회귀, 협업 필터링, 특성 학습, 주제 모델링 등에 활용
- 기울기 소멸 완화를 위한 사전 학습 및 심층 신뢰 신경망의 구성 요소

4.3.5 심층 신뢰 신경망(DBN)

사전 훈련된 여러 개의 제한된 볼츠만 머신을 층층이 쌓은 신경망

- 레이블이 없는 데이터를 이용한 비지도 학습
 - 아래층부터 RBM을 하나씩 순차적으로 사전 훈련
 - 상위 층으로 갈수록 추상적인 특성 추출
 - 학습된 가중치를 다층 퍼셉트론의 초기 가중치로 사용
 - 일반화와 추상화 과정에 활용
-

4.4 우리는 무엇을 배워야 할까?

학습 방법의 선택: 주어진 데이터와 얻고자 하는 결과에 따른 머신 러닝 또는 딥러닝 선택

- 간단한 선형 회귀·분류와 적은 데이터: 머신 러닝 활용
- 복잡한 비선형 데이터의 분류·예측, 자동 특성 추출, 많은 데이터: 딥러닝 활용
- 머신 러닝과 딥러닝을 목적 달성을 위한 도구로 이해하고 데이터 특성에 적합한 방법 선택