

5장 (Part 2 (5.3 전이학습~))

5.3 전이 학습

전이 학습(transfer learning)

- 많은 데이터로 이미 학습된 사전 학습 모델(pre-trained model)을 가져와 새로운 문제에 활용하는 방법
- 처음부터 모델을 학습하는 것보다 적은 데이터와 시간으로 학습할 수 있다는 장점이 있음.

전이 학습의 대표적인 방법: **특성 추출 기법, 미세 조정 기법**

구분	가중치 처리	주요 학습 대상
특성 추출	합성곱층의 가중치 고정	새로 구성한 데이터 분류기
미세 조정	합성곱층의 일부 또는 전체 가중치 갱신	합성곱층과 데이터 분류기

5.3.1 특성 추출 기법

특성 추출(feature extraction)


- ImageNet 데이터셋 등으로 사전 훈련된 모델을 불러온 뒤, 기존 합성곱층은 그대로 사용하고 마지막 완전연결층만 새롭게 학습하는 방법

특성 추출은 이미지 분류를 위해 두 부분으로 구성됨.

- **합성곱층**: 합성곱층과 풀링층으로 구성된 특성 추출 영역
- **데이터 분류기**: 추출된 특성을 입력받아 이미지의 클래스를 결정하는 완전연결층

사전 훈련된 합성곱층의 가중치는 고정하고, 새로운 데이터를 통과시킴.

합성곱층에서 추출된 특성을 새로운 데이터 분류기에 전달한 후, 분류기의 가중치만 학습하는 방식



특성 추출 과정

1. 사전 훈련된 모델 호출
2. 기존 합성곱층의 가중치 고정
3. 새로운 분류 목적에 맞는 완전연결층 구성
4. 새로운 데이터의 특성 추출
5. 완전연결층 중심의 학습 및 분류

사용 가능한 대표적인 이미지 분류 모델:

- Xception, Inception V3, ResNet50, VGG16, VGG19, MobileNet

특성 추출 기법의 특징

- 사전 학습 모델이 획득한 이미지 특성의 재사용
- 학습해야 하는 파라미터 수의 감소
- 학습 시간과 연산량의 감소
- 비교적 적은 데이터에 대한 활용 가능
- 사전 학습 데이터와 새로운 데이터의 특성이 유사할수록 효과적인 방식

5.3.2 미세 조정 기법

미세 조정(fine-tuning)

- 특성 추출 기법에서 더 나아가 사전 훈련된 모델의 합성곱층, 데이터 분류기의 가중치를 다시 학습하는 방법
 - 사전 학습 모델이 추출한 특성이 새로운 데이터에 적합하지 않을 경우, 새로운 데이터를 이용하여 네트워크의 가중치를 갱신하고 목적에 맞는 특성을 다시 추출하는 방식.
전체 모델을 재학습하거나, 일부 계층만 선택적으로 재학습하는 것도 가능
 - 특성 추출보다 많은 연산량이 필요하므로 GPU 사용이 권장됨

데이터셋에 따른 미세 조정 전략

데이터셋 크기	사전 학습 데이터와의 유사성	미세 조정 전략
큼	작음	모델 전체 재학습
큼	큼	합성곱층 뒷부분(완전연결층과 가까운 부분) + 데이터 분류기 학습
작음	작음	합성곱층 일부 + 데이터 분류기 학습
작음	큼	데이터 분류기만 학습

- **크고 유사성이 작은 데이터셋**: 충분한 데이터를 이용한 모델 전체의 재학습
- **크고 유사성이 큰 데이터셋**: 강한 특성이 나타나는 합성곱층 뒷부분과 분류기 재학습
- **작고 유사성이 작은 데이터셋**: 적절한 합성곱층 범위를 선택해 일부 합성곱층을 학습하고 분류기 재학습
- **작고 유사성이 큰 데이터셋**: 과적합 방지를 위해 최종 데이터 분류기인 완전연결층에 대해서만 미세 조정 기법 적용



미세 조정 과정에서 파라미터를 크게 변경하면 과적합이 발생할 수 있으므로, **정교하고 미세한 단위의 파라미터 업데이트(가중치 갱신)**이 필요함.

5.4 설명 가능한 CNN

설명 가능한 CNN(explainable CNN)

- 딥러닝의 처리 결과를 사람이 이해할 수 있는 형태로 제시하는 기술
 - CNN은 높은 성능을 제공하지만, 내부에서 어떤 특성을 이용하여 결과를 도출했는지 직접 파악하기 어려움.
⇒ 필터와 특성 맵의 시각화를 통한 처리 과정의 확인이 필요

5.4.1 특성 맵 시각화

특성 맵(feature map)(=활성화 맵(activation map))

- 입력 이미지나 이전 특성 맵에 필터를 적용하여 얻은 결과
 - 특성 맵 시각화의 목적: 특정 입력 이미지에 대해 각 계층이 입력 특성을 어떻게 감지하는지 확인하는 데 있음

시각화 과정

1. 합성곱 신경망 구성
2. 시각화할 입력 이미지 호출 및 크기 조정
3. 이미지를 텐서 형태로 변환
4. 확인할 합성곱층 선택
5. 순전파 과정에서 해당 계층의 출력 획득
6. 출력된 특성 맵의 이미지 표현

hook 의 기능


- 파이토치의 `hook` 은 각 계층에 `print` 문을 추가하지 않고도 각 계층의 활성화 함수 및 기울기 값을 확인할 수 있음.
- 순전파 과정의 입력과 출력, 활성화 값 등을 확인하기 위한 기능
 - `register_forward_hook` 을 이용하면 순전파가 실행될 때 특정 네트워크 모듈의 입력과 출력을 가져올 수 있음. 이를 통해 원하는 합성곱층의 특성 맵 확인 가능.

5.5 그래프 합성곱 네트워크

그래프 합성곱 네트워크

- 그래프 데이터를 위한 신경망

5.5.1 그래프란



- **그래프(graph):** 방향성이 있거나 없는 에지로 연결된 노드의 집합
- **노드(node, vertex):** 그래프를 구성하는 개별 원소
- **에지(edge):** 두 노드 사이의 관계를 나타내는 연결선

5.5.2 그래프 신경망

그래프 신경망(Graph Neural Network, GNN)

- 그래프 구조의 데이터를 처리하기 위한 신경망


그래프에 대한 표현은 다음과 같이 두 단계로 이루어짐.

1단계: 인접 행렬

- **인접 행렬(adjacency matrix):** 그래프의 노드 연결 관계를 $n \times n$ 행렬로 표현한 것
 - 인접 행렬 과정은 컴퓨터가 이해하기 쉽게 그래프로 표현하는 과정임

2단계: 특성 행렬


- **특성 행렬(feature matrix):** 각 노드가 가진 특성 값을 행렬로 표현한 것
 - 인접 행렬만으로는 각 노드의 구체적인 특성을 파악하기 어렵기 때문에 단위 행렬을 적용.
 - 특성 행렬의 각 행은 해당 노드가 가진 특성 값을 의미



5.5.3 그래프 합성곱 네트워크

그래프 합성곱 네트워크(Graph Convolutional Network, GCN)

- 이미지에 적용하던 합성곱을 그래프 데이터로 확장한 알고리즘
 - GCN의 핵심: 그래프 합성곱층(graph convolutional layer)
 - ⇒ 그래프 형태의 데이터를 행렬 형태로 변환함으로써 딥러닝 알고리즘의 적용이 가능해짐.



리드아웃

- 리드아웃(readout): 특성 행렬을 하나의 벡터로 변환하는 함수
 - 전체 노드의 특성 벡터에 대한 평균을 구하고, 그래프 전체를 나타내는 하나의 벡터를 생성하는 과정

GCN의 주요 활용 분야

- SNS의 관계 네트워크
- 학술 연구의 인용 네트워크
- 3D Mesh