10장 비전 트랜스포머

Vision Transform (비전 트랜스포머) : 이미지 인식을 위한 딥러닝 모델
이미지를 자연어 처리 방식처럼 분류해 보려는 시도에 의해 탄생

이미지 분류 모델에서 사용되는 CNN 모델의 합성곱 계층 방법을 사용하지 않고 트랜스포머 모델에서 사용되는 셀프 어텐션을 적용
셀프 어텐션을 사용해 전체 이미지를 한 번에 처리하는 방식으로 구현

Vit는 이미지 패치가 왼쪽 → 오른쪽, 위 → 아래 방향으로 순차적으로 입력되어 2차원 구조의 이미지 특성을 온전히 반영할 수 없음
⇒ 물체의 크기나 해상도를 계층적으로 학습하는 Swin Transformer, CvT (Convolutional Vision Transformer)

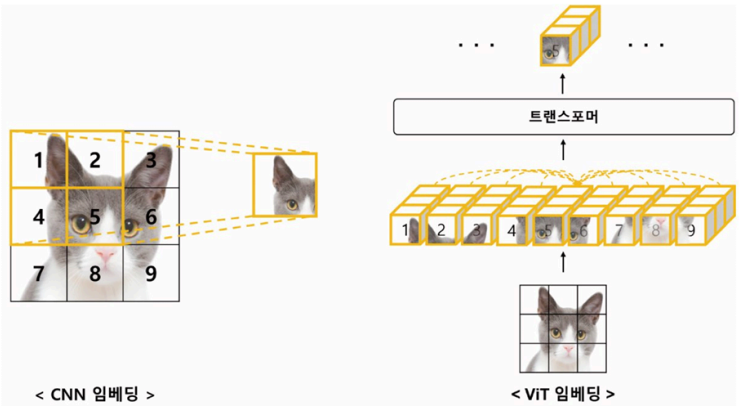
Swin Transformer는 local window를 활용해 각 계층의 어텐션이 되는 패치의 크기와 개수를 다양하게 구성해 이미지의 특징을 학습시킴
기존 셀프 어텐션을 로컬 윈도 안에 대한 어텐션, 로컬 윈도 간의 어텐션으로 수행하여 이미지 특징을 계층적으로 학습시킴
어텐션 함수에는 상대적 위치 편향을 반영하여 어텐션 값 자체에 위치적 정보를 포함시킴

CvT는 기존 합성곱 연산 과정을 ViT에 적용한 모델로 저수준 특징과 고수준 특징을 계층적으로 반영할 수 있음
어텐션 연산 과정에서 쿼리, 키, 값 중 키와 값을 기존 특징 벡터보다 축소해 계산 복잡도를 감소 시킴

ViT 계열의 모델들은 이미지 분류 작업 뿐만 아니라 광범위한 다른 컴퓨터 비전 작업에도 적용할 수 있음

ViT

이전에는 합성곱 신경망에 트랜스포머 모델의 셀프 어텐션 모듈을 적용한 모델이 많았지만, ViT는 트랜스포머 구조 자체를 컴퓨터 비전 분야에 적용한 첫번째 연구



합성곱 신경망의 임베딩은 이미지 패치 중 일부만 선택하여 학습하고 이를 통해 이미지 전체의 특징을 추출
ViT 임베딩은 이미지를 작은 패치들로 나눠 각 패치 간의 상관관계를 학습
이때 셀프 어텐션 방법을 사용해 모든 이미지 패치가 서로에게 주는 영향을 고려해 이미지의 전체 특징을 추출
이를 통해 ViT는 모든 이미지 패치가 학습에 관여하여 높은 수준의 이미지 표현을 제공할 수 있음

합성곱 신경망은 좁은 수용 영역을 가져 전체 이미지 정보를 표현하는데 수많은 계층이 필요
트랜스포머 모델은 어텐션 거리를 계산하기 때문에 한 개의 ViT 레이어로 전체 이미지 정보를 표현할 수 있음

ViT 모델은 입력 이미지의 크기가 고정되어 있어 크기가 다른 이미지를 처리하려면 전처리가 필요
합성곱 신경망과 달리 패치 간의 상대적인 위치 정보만 고려하여 이미지 변환에 취약

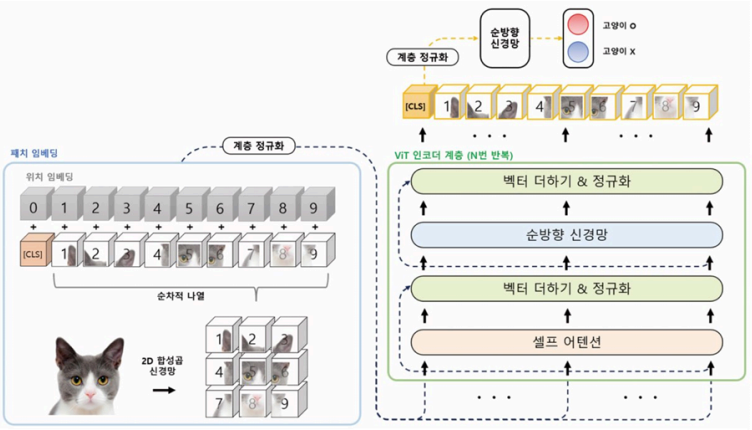
ViT의 귀납적 편향

귀납적 편향 : 일반화 성능 향상을 위한 모델의 가정

합성곱 신경망은 지역적인 특징을 강조하는 특성을 가져 이미지 데이터에서 좋은 성능을 발휘함
sequential 편향을 가진 순환 신경망 모델에서는 시각적 관계를 잘 표현하는 시계열 데이터가 많이 사용됨
하지만 이러한 특정 관계 편향이 강할수록, 다른 다양한 관계를 표현하기 어려워 귀납적 편향이 약한 모델을 선호하기도 함

ViT 모델은 입력 데이터의 다양한 쿼리, 키, 값의 임베딩 형태로 일반화된 관계를 학습하여 귀납적 편향이 거의 없음
대용량 데이터에 대해 이미지 특징들의 관계를 잘 학습하는 모델로 알려짐

ViT 모델



ViT는 패치 임베딩과 인코더 계층으로 구성
패치 임베딩과 인코더 계층을 통해 이미지의 특징을 추출하고 분류나 회귀와 같은 작업에 맞는 출력값으로 변환해 사용

패치 임베딩 : 입력 이미지를 트랜스포머 구조에 맞게 일정한 크기의 패치로 나눈 다음 각 패치를 벡터 형태로 변환
입력 이미지를 작은 패치로 분할하기 위해서는 이미지 크기를 맞추는 전처리 과정이 필요함
일정한 크기로 변경했다면 합성곱 신경망의 계층을 활용하여 전체 이미지를 패치 크기로 분할해 시퀀셜 배열을 만듦

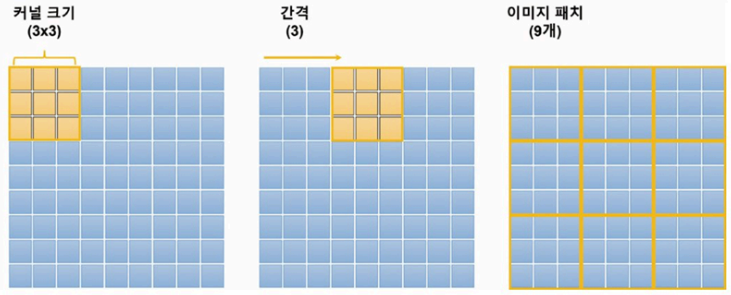


그림 10.5 이미지 패치 생성 과정

패치 임베딩을 위해서는 커널 크기와 간격을 하이퍼파라미터로 설정하여 정의해야함

분할된 이미지 배치들을 배열 형태로 나열할 때 왼쪽 → 오른쪽, 위 → 아래 순서로 배열
배열 가장 왼쪽에는 분류 토큰을 추가, 전체 이미지를 대표하는 벡터로 특정 문제를 예측하는데 사용

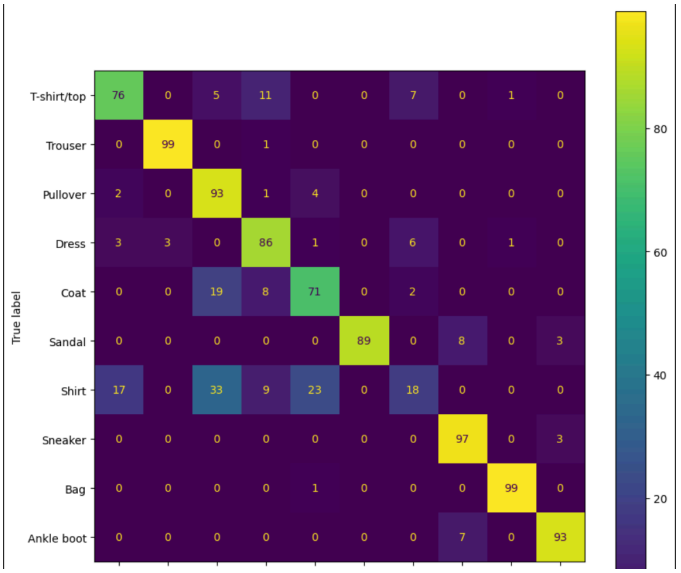
추가로 위치 임베딩을 사용하여 인접한 패치 간의 관계를 학습
패치의 위치 정보를 임베딩 벡터로 변환하고 기존 이미지 패치 벡터들을 더함

마지막으로 계층 정규화를 적용하면 패치 임베딩이 생성됨
이렇게 입력을 작은 패치로 나눠 처리하면 GPU 메모리의 한계를 극복하여 더 큰 이미지를 처리할 수 있음

인코딩 : 각 패치와의 관계 학습
패치 임베딩을 통해 이미지를 일정한 크기의 패치로 나눠 각 패치를 벡터로 변환한 후 인코더 계층에 입력으로 전달해 다양한 쿼리, 키, 값 임베딩의 관계 학습

N개의 인코더 레이어를 반복적으로 적용한 후, 마지막 레이어에서는 특별한 패치의 특징 벡터인 분류 토큰을 추출
추출한 특징 벡터는 이후 다양한 이미지 분류 및 검색 문제를 해결하는데 사용
(전체 sequential output를 사용하는 것이 아니라 전체 이미지의 특징을 잘 표현하는 분류 토큰 벡터만 사용해서 문제를 해결)

실습



*교재와 다르게 실습에서는 subset_train_dataset의 max_len = 200, epoch = 2로 설정

ViT 모델의 테스트 결과, F1-score는 약 0.8045, 테스트 손실은 1.4896으로 나타남
F1-score가 약 80%라는 점에서 모델이 이미지의 특징을 학습하여 비교적 양호한 분류 성능을 보였음을 알 수 있음
테스트 손실이 1.4896으로 나타나 일부 이미지에 대해서는 예측이 불확실하거나 잘못된 분류가 발생했을 가능성이 있음

Swin Transformer

대규모 비전 인식 모델
기존 트랜스포머는 고정된 패치 크기로 인해 세밀한 예측을 필요로 하는 의미론적 분할 작업에 적합하지 않음
⇒ 계층적 특징 맵을 구성해 1차 계산 복잡도를 가지는 스윈 트랜스포머

이미지 분류, 객체 감지, 영상 분할과 같은 인식 작업에서 강력한 성능을 냄
기존 트랜스포머 구조보다 이미지 특성을 더 잘 표현함

shifted window 기술을 이용해 입력 이미지를 일정한 크기의 패치로 분할
이 패치들을 쌓아 윈도우를 구성
구성된 윈도우 영역만 셀프 어텐션을 계산

패치를 겹쳐 더 큰 효율성을 제공
계층마다 어텐션이 수행되는 패치의 크기와 개수를 계층적으로 적용해 처리하여 높은 해상도와 다양한 크기를 가진 객체를 효율적으로 처리 가능

ViT와의 차이

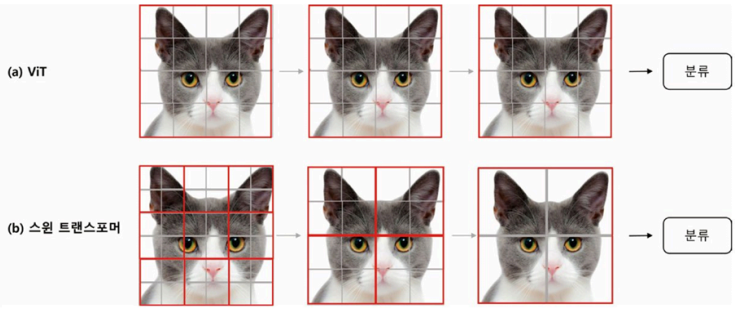


그림 10.6 ViT와 스윈 트랜스포머의 네트워크 구조

Vit는 획일적인 패치 크기와 위치에 대한 제약이 있어 다양한 이미지 크기르 가진 데이터에는 적용이 어려움
패치 단위로 입력을 받아 이미지의 공간 정보가 완전히 보존되지 않음
이미지의 패치 수가 증가하면 학습 데이터의 크기도 커져 모델 학습에 필요한 계산량이 증가함

ViT의 한계를 보완하기 위해 스윈 트랜스포머는 local window를 활용
입력 이미지를 처리하기 위해 사용되는 고정 크기의 작은 윈도우
스윈 트랜스포머에서는 shift window 기술을 사용하여 local window를 이동시켜 입력 이미지를 일정한 크기의 패치로 분할하고 특징 맵을 디오시켜 다음 계층에 사용하여 패치의 위치를 더 유연하게 다룸

ViT의 네트워크는 계층마다 전체 이미지 안에 어텐션이 수행되는 패치 크기와 개수가 동일하지만
스윈 트랜스포머는 local window를 통해 계층마다 어텐션이 되는 패치의 크기와 개수가 다름
계층적 접근 방식으로 local window가 각 패치의 세부 정보에 집중하게 됨
shift window를 통해 전역 특징을 확인할 수 있어 고해상도 이미지를 효율적으로 처리할 수 있음

표 10.4 ViT와 스윈 트랜스포머 비교

	ViT	스윈 트랜스포머
분류 헤드	[CLS] 토큰 사용	각 토큰의 평균값 사용
로컬 윈도 사용	X	O
상대적 위치 편향 사용	X	O
계층별 패치 크기	동일함	다양함

구조

스윈 트랜스포머는 이미지를 패치 파티션으로 구분한 후
선형 임베딩, 스윈 트랜스포머 블록, 패치 병합 연산을 반복적으로 수행

입력 이미지를 일정한 크기의 패치로 분할하고 각 패치에 대해 선형 임베딩 수행
(각 패치는 고정된 차원의 벡터로 변환됨)
분할된 패치들을 기반으로 스윈 트랜스포머 블록 구성 (어텐션 계층, 계층 정규화, 다층 퍼셉트론 등 패치 간 상호작용 수행)
패치를 병합해 전체 이미지에 대한 분류를 수행 (분할된 패치들을 순차적으로 합치면서 이미지의 전체적인 정보를 추출하는 방식 사용)

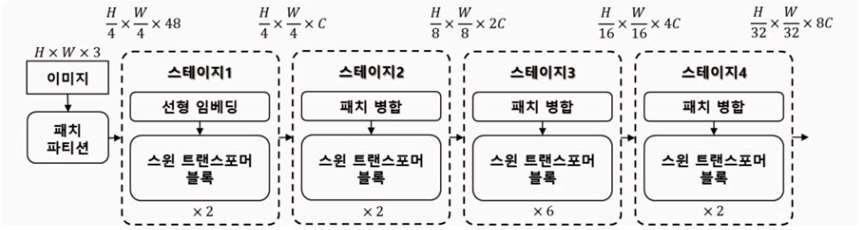


그림 10.7 스윈 트랜스포머 구조

총 4개의 스테이지로 구성, 각 스테이지는 서로 다른 해상도와 패치 크기를 가짐

스테이지 1에서는 패치들이 선형 임베딩된 후 스윈 트랜스포머 블록에 전달됨
스테이지 2, 3, 4에서는 패치 병합 후 각 스윈 트랜스포머 블록에 전달됨
패치 병합은 모델의 매개 변수를 줄이기 위해 이미지 텐서를 재정렬해 저차원 임베딩을 수행

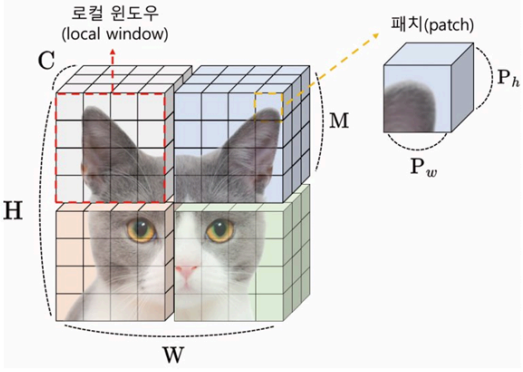


그림 10.8 패치 파티션 구조

패치 파티션 : 입력 이미지를 작은 사각형 패치로 분할해 처리하는 방식
분할된 패치는 트랜스포머 계층의 입력으로 사용됨
입력 이미지의 공간 정보를 보존하고 트랜스포머 계층에 대한 계산 효율성을 높임

패치 병합 : 인접한 패치들의 정보를 저차원으로 축소하는 과정

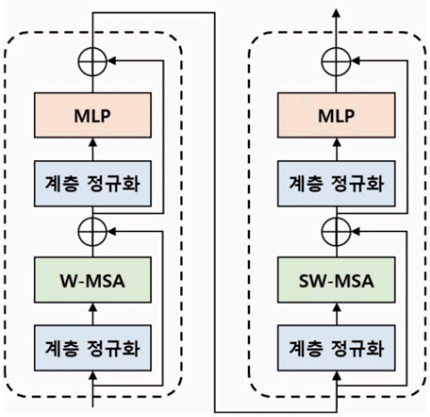


그림 10.9 스윈 트랜스포머 블록 구조

스윈 트랜스포머 블록은 패치 파티션 이후 4개의 스테이지 안에서 반복 적용됨 (선형 임베딩 또는 패치 병합 이후 수행)
계층 정규화, W-MSA, MLP, SW-MSA 등으로 구성됨

트랜스포머 모델에서 사용되던 MSA 방식이 아닌 W-MSA와 SW-MSA로 구성

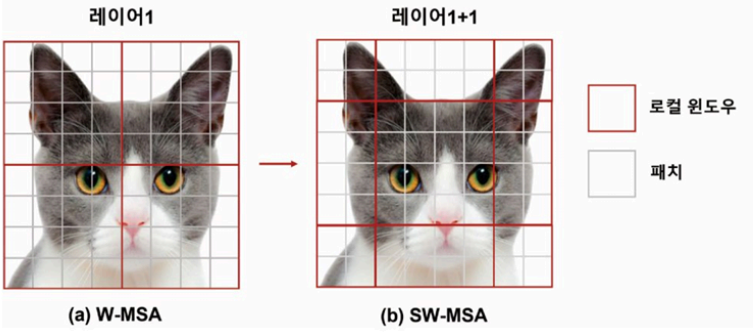


그림 10.10 W-MSA와 SW-MSA 어텐션 영역 비교

W-MSA : 로컬 윈도를 사용하는 멀티 헤드 셀프 어텐션
입력 특징 맵을 중첩되지 않게 나눈 다음 각 윈도에서 독립적으로 셀프 어텐션을 수행

이미지에서 일정한 크기의 윈도 영역을 설정하고 해당 영역 내 픽셀 간의 어텐션을 계산
이를 통해 이미지 내의 전체적인 어텐션을 수행하고 특정 위치에 대한 정보 추출
각 윈도 내 지역적인 특징 분석 가능
전체 입력에 대한 셀프 어텐션 비용을 2차 계산 복잡도에서 1차로 줄임

연산량은 감소했지만 윈도 내부의 이미지 패치 영역에만 셀프 어텐션을 수행하는 단점이 존재
⇒ SW-MSA : 윈도 사이의 연결성을 구축해 윈도 간의 관계성 정보 추출

SW-MSA 방식은 로컬 윈도 간의 셀프 어텐션을 수행하기 위해 W-MSA에서 사용된 로컬 윈도 개수가 더 많아 더 많은 셀프 어텐션 연산을 요구
⇒ 순환 시프트와 어텐션 마스크 사용

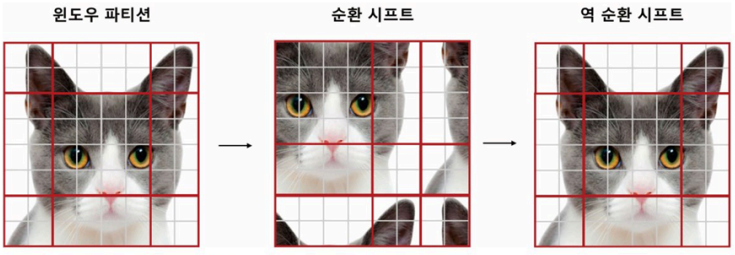


그림 10.11 순환 시프트를 활용한 SW-MSA 어텐션 계산 과정

순환 시프트 : 로컬 윈도가 이동할 때 이동한 위치의 정보를 이전 위치에서 가져오는 것
이동된 위치에서 연산을 수행하지 않도록 어텐션 마스크를 사용해 방지

역순환 시프트 : 순환 시프트 단계에서 셀프 어텐션을 수행한 다음 원래 로컬 윈도 구조로 다시 복원하는 역할

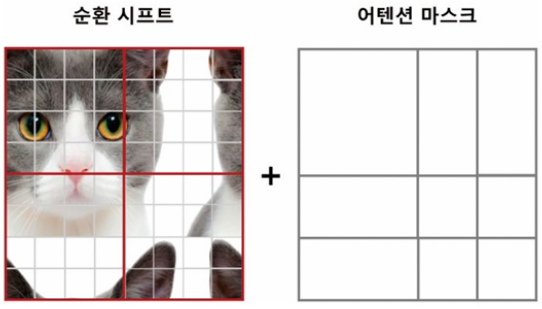


그림 10.12 순환 시프트 단계에서 마스크를 활용한 셀프 어텐션 구조

순환 시프트와 함께 어텐션 마스크를 사용해서 로컬 윈도 간의 셀프 어텐션 연산을 효율적으로 수행
어텐션 마스크는 순환 시프트를 통해 이동된 윈도에 대한 정보를 보조낳면서도 불필요한 연산을 줄이고 효율적인 계산을 가능하게 함

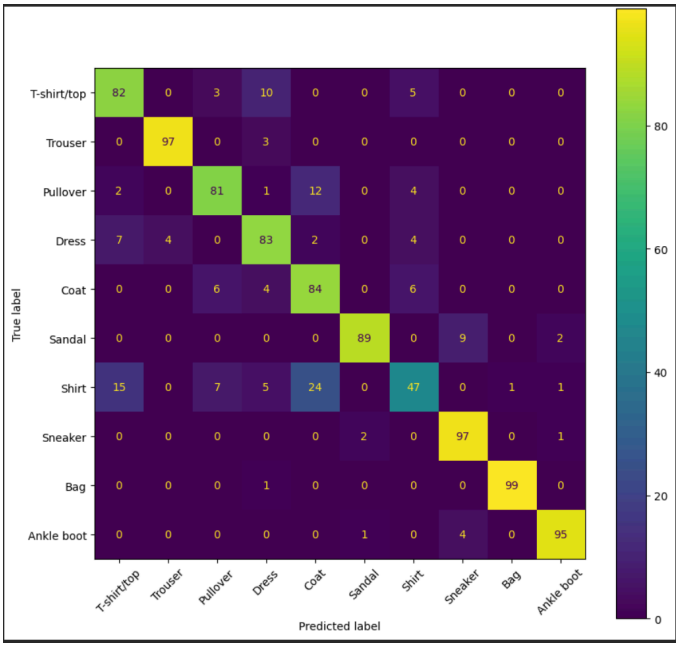
스윈 트랜스포머의 셀프 어텐션은 ViT와 다르게 상대적 위치 편향을 고려함
상대적 위치 편향 : 로컬 윈도 안에 있는 패치 간의 상대적인 거리를 임베딩하는 목적



그림 10.13 상대적 위치 편향 계산 과정

이미지 패치 간의 상대적인 거리는 X축과 Y축으로 표기
X축은 두 패치 간의 가로 방향 거리를 의미
Y축은 세로 방향 거리르 의미

실습



F1-score는 0.8504, 테스트 손실은 0.5166
모델이 이미지의 특징을 효과적으로 학습하여 비교적 높은 분류 성능을 보였음

앞서 실험한 ViT 모델과 비교하면 Swin Transformer는 F1-score가 약 4.59 %p 높고 테스트 손실도 크게 감소
테스트의 실행 시간도 단축됨

이러한 결과는 Swin Transformer가 지역적인 특징을 추출하고 계층적으로 처리하는 구조를 통해 이미지의 세부 특징을 효과적으로 학습했을 가능성을 보여줌

Swin Transformer가 이번 실습에서는 ViT보다 분류 성능과 테스트 처리 속도 모두 우수한 결과를 보임

CvT

Convolutional Vision Transformer
합성곱 신경망 구조에서 활용하는 계층형 구조를 ViT에 적용한 모델

ViT가 모든 패치에 대해 동일한 크기와 간격을 사용해서 이미지의 물체 크기나 해상도를 계층적으로 학습하기 어려운 문제점을
스윈 트랜스포머에서는 트랜스포머 블록마다 다른 로컬 윈도 크기를 사용해 해결
CvT에서는 합성곱 신경망에서 사용하는 계층적 구조를 ViT에 적용해 이미지의 지역 특징과 전역 특징을 모두 활용해서 해결

합성곱 계층의 지역 특징을 추출하고 ViT의 셀프 어텐션 계층으로 전역 특징을 결합해 이미지를 처리
스윈 트랜스포머보다 더 적은 수의 매개변수로도 비슷한 수준의 성능을 보임

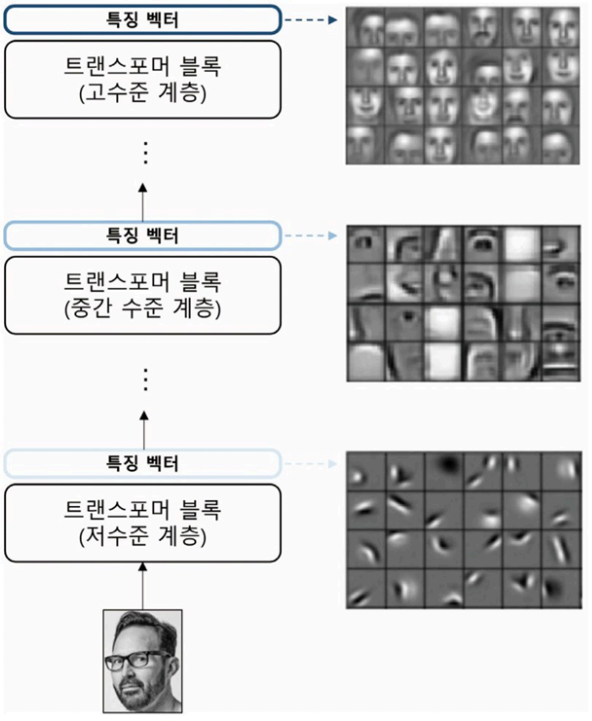


그림 10.14 CvT 모델의 계층적 특징 구조 예시

얼굴 이미지를 입력한다면
저수준 계층에서는 선 또는 점에 대한 특징을 표현
중간 수준에서는 눈이나 귀와 같은 특징을 표현

고수준 계층에서는 얼굴 구조에 대한 특징을 표현
= CvT의 계층형 구조는 물체의 크기나 해상도를 더 잘 표현할 수 있음

ViT는 이미지를 패치 단위로 분할하여 입력
패치를 겹치지 않게 처리해 모델이 이미지의 전체 정보를 학습하게 함
CvT는 이미지를 처리하기 전에 합성곱 연산을 통해 특징 맵을 추출
이를 통해 유의미한 패턴을 추출하고 일정한 크기의 패치로 나눠 트랜스포머 모델의 입력으로 사용
입력되는 패치들은 겹쳐 학습

ViT는 패치 임베딩과 선형 임베딩 사용
CvT는 합성곱 연산을 통해 이미지를 학습 → 토큰에 대한 위치 임베딩을 하지 않아도 모델의 성능 저하 없이 다양한 해상도를 가진 이미지를 처리할 수 있음

합성곱 임베딩

합성곱 토큰 임베딩 : 2D로 재구성된 토큰 맵에서 중첩 합성곱 연산을 수행하는 임베딩
ViT에 계층적인 합성곱 신경망의 성질을 추가하기 위해 사용

기존 트랜스포머 모델은 이미지의 특징을 추출하기 위해 이미지 패치를 사용
선형 임베딩을 통해 쿼리, 키, 값 임베딩으로 변환
→ 이미지의 근본적인 2D 모양의 구조를 잃게 됨

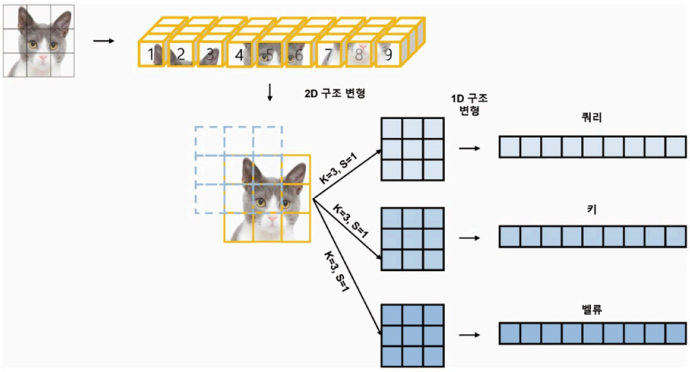


그림 10.15 2D 합성곱 기반의 어텐션 임베딩

CvT는 이미지의 2D 구조를 보존하면서도 셀프 어텐션을 계산하는 방식을 사용
이미지 패치를 2D 합성곱 임베딩을 사용해 쿼리, 키, 값 임베딩으로 변환
변환된 임베딩을 사용해 셀프 어텐션을 계산하고 출력을 생성

어텐션에 대한 합성곱 임베딩 : 2D로 재구성된 토큰맵에서 분리 가능한 합성곱 연산을 적용해 성능 저하 및 계산 복잡도를 낮추는 연산

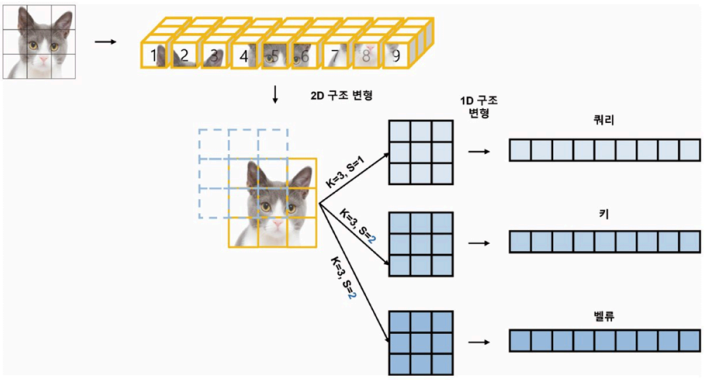


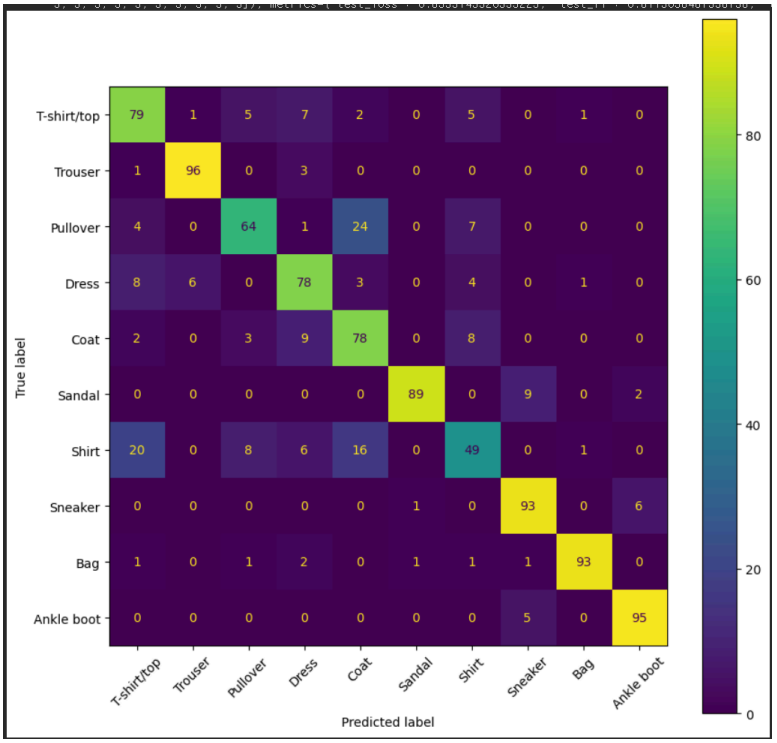
그림 10.16 2D 합성곱 기반의 축소된 어텐션 임베딩

일반적으로 쿼리, 키, 값 임베딩은 차원을 동일하게 설정하지만
CvT는 매개변수의 수를 줄이기 위해 쿼리, 키, 값의 차원을 축소시킴

트랜스포머 계층이 깊어질수록 패치 간의 관계를 학습하는 길이를 축소시키는 대신
벡터의 차원을 증가시켜 모델의 매개변수 수를 감소시킴

이미지 패치 크기가 줄어든 만큼 임베딩 차원을 늘리는 방법을 택해 네트워크의 안정성을 향상시키고 모델 설계를 단순화함

실습



F1-score는 0.8119, 테스트 손실은 0.6533

모델	F1-score	Test Loss	실행 시간
ViT	80.45%	1.4896	12.65초
Swin Transformer	85.04%	0.5166	6.06초
CvT	81.19%	0.6533	7.77초

세 모델의 성능 비교

ViT는 이미지를 일정한 크기의 패치로 나누고 셀프 어텐션을 통해 패치 간 전역적인 관계를 학습하지만 이미지의 지역적 특징을 직접 반영하는 구조가 상대적으로 부족함
CvT는 합성곱 연산을 트랜스포머에 결합하여 이미지의 지역적 특징과 공간적 정보를 효과적으로 추출
이러한 구조적 차이가 이번 실습에서 CvT가 ViT보다 높은 f1-score와 낮은 손실을 기록하는데 영향을 주었을 가능성이 있음

swin transformer는 이미지를 윈도우 단위로 나누어 셀프 어텐션을 수행하고 시프트 윈도우를 통해 서로 다른 윈도우 간의 정보도 학습
계층적 구조를 통해 다양한 크기의 특징을 추출
CvT도 합성곱과 계층적 구조를 활용하지만 swin transformer는 윈도우 기반 어텐션을 통해 지역적 특징과 주변 영역의 관계를 효율적으로 학습한다는 차이가 있음
이러한 swin transformer의 구조가 이번 실습의 이미지 분류에 더 유리하게 작용했음

결과적으로 swin transformer가 가장 우수한 성능을 보였고 CvT는 ViT보다 조금 개선된 결과를 보임
이를 통해 이미지의 지역적 특징과 공간적 구조를 고려하는 방식이 분류 성능 향상에 도움이 될 수 있음을 확인함